





- Sqoop简介
- Sqoop原理
  - Sqoop使用



### 1.1 什么是Sqoop

- ➤ Sqoop项目始于2009年,早期为Hadoop的第三方模块,后来成为Apache的独立项目
- > Sqoop是一个主要在Hadoop和关系数据库之间进行批量数据迁移的工具
  - Hadoop: HDFS, Hive, HBase, Inceptor, Hyperbase
  - 面向大数据集的批量导入导出
    - 将输入数据集分为N个切片,然后启动N个Map任务并行传输
  - 支持全量、增量两种传输方式

## ➤ 提供多种Sqoop连接器

- 内置连接器
  - 经过优化的专用RDBMS连接器: MySQL、PostgreSQL、Oracle、DB2、SQL Server、Netzza等
  - 通用的JDBC连接器: 支持JDBC协议的数据库
- 第三方连接器
  - 数据仓库: Teradata
  - NoSQL数据库: Couchbase



# ➤ Sqoop 1与 Sqoop 2的区别

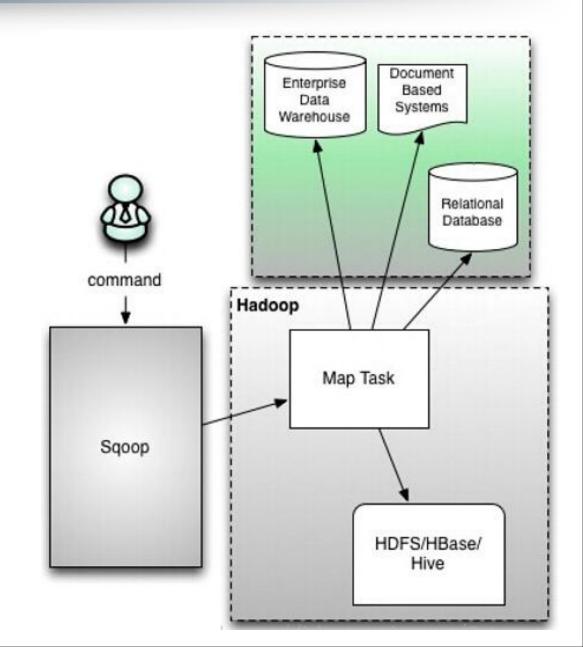
• 二者完全不兼容,无法平滑升级

|                    | Sqoop 1         | Sqoop 2                   |
|--------------------|-----------------|---------------------------|
| 版本号                | 1.4.x (1.4.7)   | 1.99.x (1.99.7)           |
| 系统架构               | 仅使用一个Sqoop客户端   | 引入Sqoop Server,集中管理连接器    |
| 访问方式               | CLI             | CLI、REST API、Java API、Web |
| 安全机制               | 命令中包含用户名、密码     | 基于角色的安全机制                 |
| RDBMS连接器           | 经过优化的专用连接器,速度较快 | 通用的JDBC连接器,性能下降           |
| RDBMS → Hive/HBase | 直接导入            | 不直接导入,先存入HDFS             |
| Hive/HBase → RDBMS | 不直接导出,先存入HDFS   | 不直接导出,先存入HDFS             |



# ➤ Sqoop 1优缺点

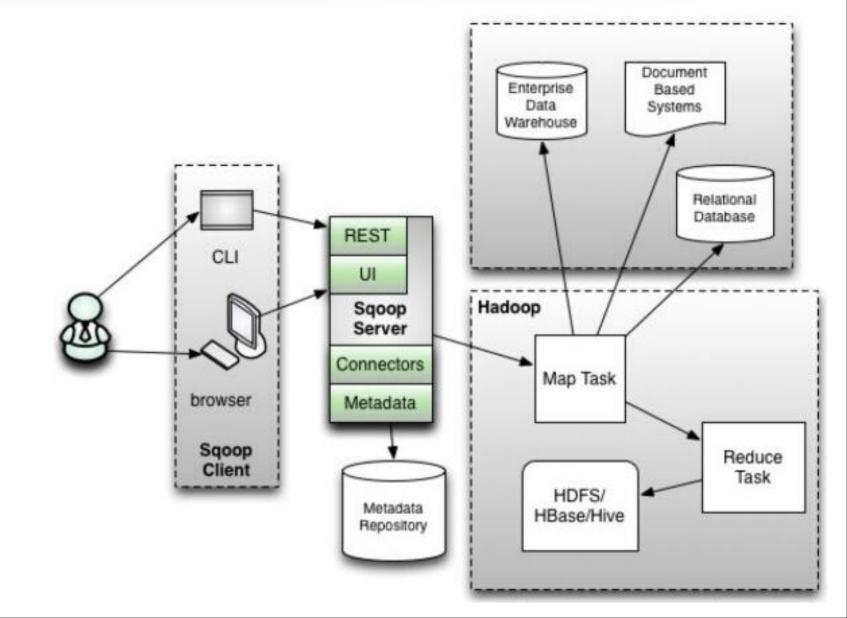
- 优点
  - 架构简单
  - -部署简单
  - 功能全面
  - 稳定性较高
  - 速度较快
- 缺点
  - 访问方式单一
  - 命令行方式容易出错,格式紧耦合
  - 安全机制不够完善, 存在密码泄露风险



## 1.2 Sqoop版本

# ➤ Sqoop 2优缺点

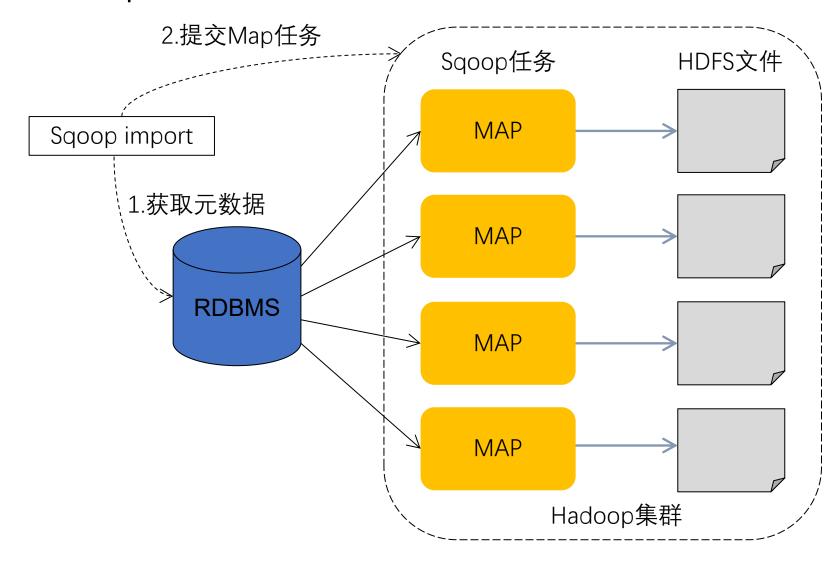
- 优点
  - 访问方式多样
  - 集中管理连接器
  - 安全机制较完善
  - 支持多用户
- 缺点
  - 架构较复杂
  - 部署较繁琐
  - 稳定性一般
  - 速度一般





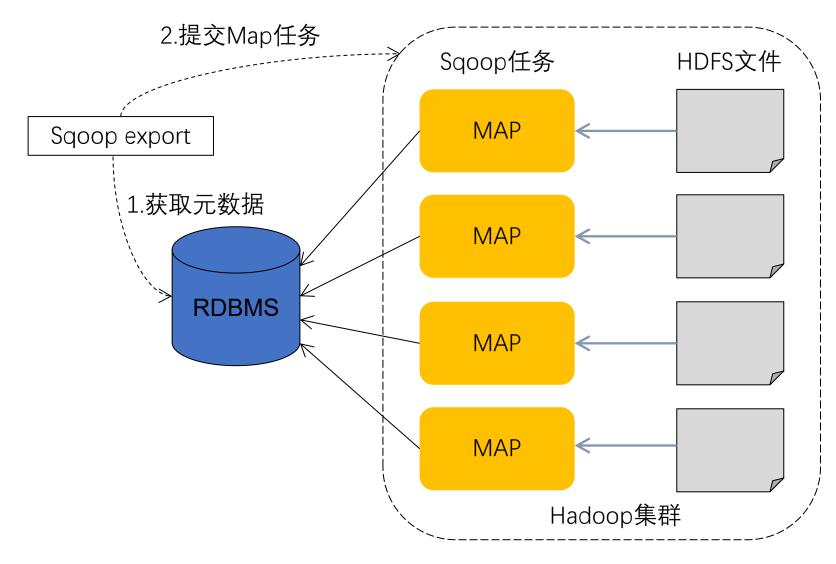
# 2.1 数据导入

## ➤ RDBMS → Hadoop





# ➤ Hadoop → RDBMS







## ➤ 安装Sqoop

- 安装TDH Client (集成Sqoop)
  - TDH Client下载: Transwarp Manager → 管理 → 下载客户端(tdh-client.tar),并解压
  - TDH Client初始化: 执行TDH Client目录下的init.sh脚本
- 安装开源Sqoop
  - RedHat: yum install sqoop; Suse: zypper install sqoop

#### > 准备数据库驱动

• 将MySQL的JDBC驱动(mysql-connector-java-5.1.31.jar)拷贝到TDH Client目录下的sqoop/lib

#### ▶ 测试

• 执行以下命令,若正常列出数据库,则说明Sqoop安装成功

/\* 列出MySQL中的所有数据库 \*/

# sqoop list-databases --connect jdbc:mysql://192.168.0.123:3316/ --username root --password transwarp

## ➤ Sqoop命令的两种形式

- 命令行
- 命令行+配置文件

```
/* 列出MySQL中的所有数据库 */
# sqoop list-databases --connect jdbc:mysql://192.168.0.123:3316/ --username root --password transwarp
# sqoop --options-file /users/homer/work/import.txt
```

```
/* 配置文件import.txt */
list-databases
--connect
jdbc:mysql://192.168.0.123:3316/
--username
root
--password
transwarp
```

### ➤ 列出RDBMS的所有数据库

```
/* 明文密码 */
# sqoop list-databases \
 --connect jdbc:mysql://192.168.0.123:3316/\
 --username root \
 --password transwarp
/* 手工输入密码 */
# sqoop list-databases \
 --connect jdbc:mysql://192.168.0.123:3316/\
 --username root \
 -P
/* 密码文件 */
# sqoop list-databases \
 --connect jdbc:mysql://192.168.0.123:3316/\
 --username root \
 --password-file file:/root/pwd
```

| Command Options | Description |
|-----------------|-------------|
| list-databases  | 列出所有数据库     |
| connect         | JDBC连接      |
| username        | 用户名         |
| password        | 明文密码        |
| -P              | 手工输入密码      |
| password-file   | 密码文件(400权限) |



## > 列出数据库的所有表

```
/* 明文密码 */
# sqoop list-tables \
 --connect jdbc:mysql://192.168.0.123:3316/testdb \
  --username root \
 --password transwarp
/* 手工输入密码 */
# sqoop list-tables \
 --connect jdbc:mysql://192.168.0.123:3316/testdb \
 --username root \
 -P
/* 密码文件 */
# sqoop list-tables \
 --connect jdbc:mysql://192.168.0.123:3316/testdb \
  --username root \
 --password-file file:/root/pwd
```

| Command Options | Description   |
|-----------------|---------------|
| list-tables     | 列出所有表         |
| connect         | JDBC连接        |
| username        | 用户名           |
| password        | 明文密码          |
| -P              | 手工输入密码        |
| password-file   | 用户密码文件(400权限) |



### > 全量数据导入

```
/* 将数据全量导入HDFS */
# sqoop import \
 --connect jdbc:mysql://192.168.0.123:3316/testdb \
 --username root \
 --password transwarp \
 --query "select * from t1 where \$CONDITIONS" \
 --target-dir /user/root/person_all \
 --fields-terminated-by "\\01" \
 --hive-drop-import-delims \
 --null-string "\\N" \
 --null-non-string "\\N" \
 --split-by id \
 -m 6 \
```

| Command Options             | Description                        |
|-----------------------------|------------------------------------|
| import                      | 数据导入                               |
| query                       | SQL查询语句                            |
| target-dir                  | HDFS目标目录(确保目录不存在,<br>否则会报错)        |
| fields-terminated-by        | 列分隔符                               |
| hive-drop-import-<br>delims | 删除数据中包含的Hive默认分隔符(^A, ^B, \n)      |
| null-string                 | string类型空值的替换符(Hive中<br>Null用\n表示) |
| null-non-string             | 非string类型空值的替换符                    |
| split-by                    | 数据切片字段(int类型,m>1时必<br>须指定)         |
| -m                          | Mapper任务数,默认为4                     |

## ➤ 基于递增列的增量数据导入(Append方式)

```
/* 将递增列大于阈值的数据增量导入HDFS */
# sqoop import \
 --connect jdbc:mysql://192.168.0.123:3316/testdb \
 --username root \
 --password transwarp \
 --query "select id, name from testdb where
   \$CONDITIONS"\
 --target-dir /user/root/person all \
 --split-by id \
 -m 6 \
 --incremental append \
 --check-column id \
 --last-value 4
```

| Command Options    | Description                                 |  |
|--------------------|---|--|
| incremental append | 基于递增列的增量导入(将递增列<br>大于阈值的所有数据增量导入<br>Hadoop) |  |
| check-column       | 递增列 (int)                                   |  |
| last-value         | 阈值(int)                                     |  |



- ➤ 基于时间列的增量数据导入 (LastModified方式)
  - 对比Append方式,LastModified方式可导入更新数据

```
/* 将时间列大于等于阈值的数据增量导入HDFS */
# sqoop import \
 --connect jdbc:mysql://192.168.0.123:3316/testdb \
 --username root \
 --password transwarp \
 --query "select id, name from testdb where
   \$CONDITIONS"\
 --target-dir/user/root/person all\
 --split-by id \
 -m 1 \
 --incremental lastmodified \
 --merge-key id \
 --check-column time \
 --last-value "2015-08-25 03:12:46"
```

| Command Options          | Description                           |
|--------------------------|---------------------------------------|
| incremental lastmodified | 基于时间列的增量导入(将时间列大于等于阈值的所有数据增量导入Hadoop) |
| merge-key                | 合并列(主键,合并键值相同的记录)                     |
| check-column             | 时间列(timestamp)                        |
| last-value               | 阈值(timestamp)                         |



### ➤ 从Oracle分区表中导入数据

```
/* 将Oracle分区表数据全量导入HDFS */
# sqoop import
 --connect jdbc:oracle:thin:@$IP:$PORT/$SID \
 --username xxxx \
 --password xxxx \
 --query "select $COLUMNS from $ORACLE_USERNAME.$TABLENAME partition($PARTITION)
   where \$CONDITIONS" \
 --target-dir /data/sqoop/$USERNAME/$TABLENAME/$PARTITION \
 -m 1 \
 --fetch-size 10000 \
 --fields-terminated-by "\\01" \
 --hive-drop-import-delims \
 --null-string "\N" \
 --null-non-string "\\N" \
```

### > 并发导入

- 通过-m参数,设置多个Map任务,实现数据并发导入
- •-m大于1时,必须设置--split-by,并利用哈希取模实现数据均匀切片,避免数据倾斜

| RDBMS  | Command Options   |  |
|--------|---|--|
| Oracle | -m 20split-by "MOD(ORA_HASH(col), 20)"boundary-query "select 0, 19 from dual" |  |
| DB2    | -m 20split-by "MOD(HASHEDVALUE(col), 20)"boundary-query "VALUES (0, 19)"      |  |



#### ▶ 并发度控制

- 数据导入的性能瓶颈
  - RDBMS和Hadoop集群的网络带宽
  - RDBMS的IO限制
- •数据导入的性能可按每个Map任务的处理速度5~10MB/s做估算
- Map个数并非越多越好,过多的Map会导致RDBMS发生IO抢占,反而降低整体性能
- RDBMS的导出速度控制在60~80MB/s
- •实战中一般设置4~8个Mapper任务,通过Query人工均匀切分数据



